AI RUNTIME AUDIT
Raport przykładowy

OLA-SAMPLE-20261104-A | 4 listopada 2026 | dane testowe

Zakres wniosku	Status
Przebieg CI i samodzielna rekonstrukcja dowodów	VERIFIED
Zatwierdzenie kandydata przez człowieka	REVIEW
Produkcja i jakość rozumowania modelu	Poza zakresem

Rzeczywisty przebieg. Dowody do pobrania.

NINA wykonała kontrolowane zadanie z użyciem lokalnego Ollama. IGOR sprawdził wynik i dowody. Odbiorca może lokalnie odtworzyć łańcuch oraz porównać prompty i odpowiedzi modelu, bez kluczy API.

6	8	19/19
wywołań modelu	rekordów dowodowych	sprawdzeń lokalnych

Sprawdzony przypadek

Zadanie: obliczenie 17 * 23. Oczekiwany i zaobserwowany wynik narzędzia: 391. Model: qwen2.5:0.5b-instruct. Test działał na jednorazowym tenantcie CI. Nie zawiera danych klienta.

Wykonanie: 04.11.2026, 14:07:48 - 14:08:18 CET (Europe/Brussels). Wynik odtworzono lokalnie na pobranym, niezmienionym archiwum.

Co odbiorca może potwierdzić

1. Zgodność archiwum z digestem z GitHub.
2. Ciągłość wszystkich ośmiu rekordów V2 od genesis.
3. Powiązanie sześciu kontekstów, promptów i odpowiedzi Ollama.
4. Wynik obliczenia, siedem zdarzeń replay oraz hash raportu.
5. Zachowanie statusu REVIEW przy braku zatwierdzenia człowieka.

VERIFIED dotyczy wyłącznie powyższego, uchwyconego przebiegu. Raport nie stanowi oceny całego OLA ani zgody na produkcję.

Pomiar i granice dowodu

Sześć rzeczywistych wywołań Ollama

Rola	Czas (s)	Tokeny	Zakończenie
codeact	2.004	16	stop
react	4.029	42	stop
agentic_rag	5.787	96	limit tokenów
mcp_tool_use	6.274	96	limit tokenów
self_reflection	6.015	96	limit tokenów
multi_agent	5.178	87	stop

Suma czasów żądań: 29.287 s. Pomiar obejmuje żądanie, inferencję i przesłanie odpowiedzi. Nie jest pomiarem SLO, p95 ani obciążenia produkcyjnego.

Wnioski, których ten przykład nie uzasadnia

Jakość AI: prompt podaje oczekiwany wynik 391. Kolejność i narzędzia są zaprogramowane. Wynik liczy kalkulator; tekst modelu nie steruje działaniami. Test nie mierzy inteligencji ani autonomii.

Kompletność tekstu: trzy odpowiedzi zakończyły się przez limit 96 tokenów. Nie oceniono ich poprawności semantycznej ani kompletności JSON.

Zgoda człowieka: REVIEW dotyczy zatwierdzenia kandydata po obliczeniu testowym. Ten przebieg nie dowodzi bramki przed wykonaniem każdego narzędzia.

Replay: odtworzono zapisane zdarzenia. Nie wykonywano drugiej inferencji modelu ani testu identyczności odpowiedzi między uruchomieniami.

Granica zaufania: GitHub CI i rejestrator ruchu są wspólną granicą wykonawczą. Hashe wykrywają zmianę danych względem zaufanej kotwicy; nie są atestacją sprzętową ani podpisem tożsamości.

Testy prób podmiany

19/19 PASS: jeden prawidłowy pakiet zaakceptowany, 18 przypadków negatywnych odrzuconych. Obejmują zmianę wyniku, modelu, odpowiedzi, zadania, tenanta, źródła, replay i zgody człowieka. Wybrane próby przeliczały łańcuch po zmianie danych, aby sprawdzić także powiązania logiczne.

Sprawdź samodzielnie

Wymagany Python 3.10 lub nowszy. Weryfikacja działa bez pip, Dockera, modelu i sekretów. Po rozpakowaniu ZIP otwórz terminal w katalogu z plikiem verify.py.

1. Sprawdź niezależne źródło

Porównaj pole digest i workflow_run.head_sha w metadanych artefaktu GitHub. Własna kopia manifestu z otrzymanego pakietu nie jest niezależnym potwierdzeniem pochodzenia.

GitHub Actions: przebieg 41835035434
GitHub API: artefakt 13325371050

2. Uruchom weryfikator (PowerShell)

```
$sourceSha = '1dd3b0d1b09ca191f91b490e45673ffa95de5b4a'
$artifactSha = '43b742e6938ea40a637c876a1f19592da20034a1b52ead611dac6827cc962a68'
py -3 verify.py --expected-source $sourceSha `
  --expected-artifact-sha256 $artifactSha
py -3 test_verify.py
```

Na macOS/Linux użyj python3 zamiast py -3. Pełna instrukcja, w tym katalog na dysku D, znajduje się w README.md.

Oczekiwany wynik	Wartość
Status weryfikatora / kod wyjścia	PASS / 0
Rekordy / wywołania modelu / wynik	8 / 6 / 391
Human Gate / produkcja	REVIEW / NOT_ASSESSED
Testy lokalne	19/19 PASS

3. Zachowaj kotwice

Źródło badanego przebiegu:

`1dd3b0d1b09ca191f91b490e45673ffa95de5b4a`

SHA-256 oryginalnego archiwum evidence/runtime-original.zip:

`43b742e6938ea40a637c876a1f19592da20034a1b52ead611dac6827cc962a68`

Kod eksportu jest w roboczym PR #168. Badany przebieg pochodzi z gałęzi kandydującej. Zachowano oryginalne bajty dowodów; losowe identyfikatory testu pozostają wyłącznie w pakiecie technicznym.